Análisis de Datos Espaciales

Sesión 1: Introducción y Conceptos Fundamentales

Daniela Opitz
Departamento de Informática
Universidad Técnica Federico Santa María

2026

Reglas del Curso

Clases

- Veremos teoría y práctica en la cátedra.
- Usaremos **Python**
- De vez en cuando leeremos algunos papers
- Trabajos que requieran presentación oral serán evaluado en clases en hora de cátedra

Evaluaciones

- El cursos contempla dos tipos de evaluaciones, tareas cortas **individuales** y un proyecto grupal final **de hasta 2 personas**.
- Cada grupo definirá un proyecto de que involucre el análisis de datos espaciales (ciencia de datos geográficos)
- El proyecto tendrá **tres hitos** dentro de los cuales el último hito será la evaluación final que consiste en una **presentación final oral** y un **informe**.
- El informe tiene forma de **infografía**.
- También se premiará la asistencia a clases y la participación en la actividades del curso.

Evaluaciones

FORMULA

EVALUACION	PESO
PF - Proyecto Final	50%
T - Tareas	40%
P - Participación	10%

Nota Final = 0.5 × PF + 0.4 × T + 0.1 × P

PROYECTO FINAL

HITO	PESO	DESCRIPCIÓN
H1 — Primer hito	15%	Entrega inicial. Instancia formativa para recibir feedback temprano.
H2 — Segundo hito	25%	Entrega intermedia. Idealmente debe incorporar el feedback del H1.
H3 — Tercer hito	60%	Entrega final.

Evaluaciones

TAREAS

EVALUACION	PESO
T1 - Tarea 1	50%
T2 - Tarea 2	50%

PARTICIPACION

HITO	PESO	DESCRIPCIÓN
P — Participación	10%	Se evaluarán N actividades de clases prácticas, se consideran las mejores X (pueden faltar X clases prácticas)

Contexto

Censos de 1865 y 1940

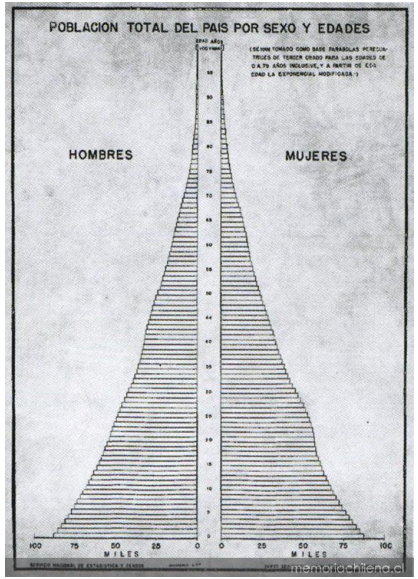

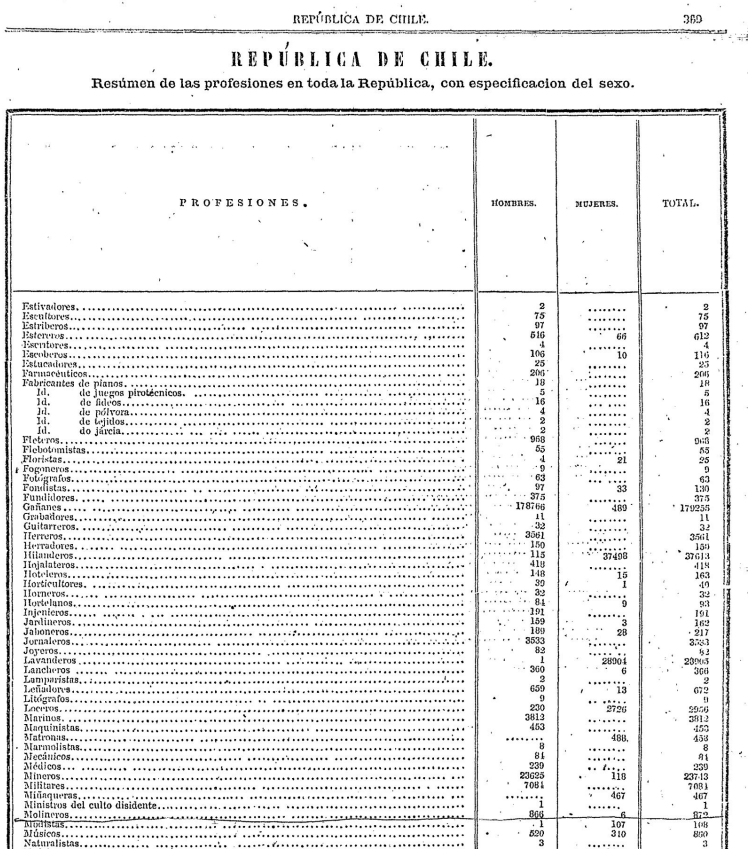

REPÚBLICA DE CHILE. 369

REPÚBLICA DE CHILE.

Resúmen de las profesiones en toda la República, con especificacion del sexo.

PROFESIONES.	HOMBRES.	MUJERES.	TOTAL.
Estivadores	2	.....	2
Escultores	75	.....	75
Estriberos	97	.....	97
Esterros	546	66	612
Escritores	4	.....	4
Escoberos	106	10	116
Estucadores	25	.....	25
Farmacéuticos	206	.....	206
Fabricantes de planos	18	.....	18
Id. de juegos pirotécnicos	5	.....	5
Id. de lídeos	16	.....	16
Id. de pólvora	4	.....	4
Id. de tejidos	2	.....	2
Id. de jarcia	2	.....	2
Fleteros	968	.....	968
Flebotomistas	55	.....	55
Floristas	4	21	25
Fogoneros	9	.....	9
Fotógrafos	63	.....	63
Fondistas	97	33	130
Fundidores	375	.....	375
Gañanes	178766	489	179255
Grabadores	11	.....	11
Guitarreros	32	.....	32
Herreros	3561	.....	3561
Herradores	159	.....	159
Hilanderos	115	37498	37613
Hojalateros	418	.....	418
Hoteleros	148	15	163
Horticultores	39	1	40
Hornero	32	.....	32
Hortelanos	84	9	93
Injenieros	191	.....	191
Jardineros	159	3	162
Jabonero	189	28	217
Jornaleros	3533	.....	3533
Joyeros	82	.....	82
Lavanderos	1	28904	28905
Lancheros	360	6	366
Lampuristas	2	.....	2
Leñadores	659	13	672
Litógrafos	9	.....	9
Lecheros	220	2726	5956
Marinos	3813	.....	3813
Maquinistas	453	.....	453
Matronas	.....	488	488
Marmolistas	8	.....	8
Mecánicos	81	.....	81
Médicos	239	.....	239
Mineros	23629	118	23713
Militares	7081	.....	7081
Miñaqueras	.....	467	467
Ministros del culto disidente	1	.....	1
Molineros	866	6	872
Modistas	1	107	108
Músicos	559	310	869
Naturalistas	3	.....	3

Fuentes de Datos Actuales

- Encuestas
- Censos
- Conteos
- Sensores
- GPS
- Registros

Oportunidad

Hoy hay más dispositivos generando trazas digitales que personas.

Trazas Digitales

Cornershop

transbank.
APOYANDO NEGOCIOS

cabify

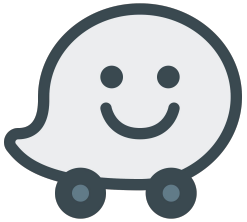

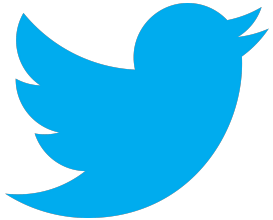

SOSAFE

Google

Datos Geográficos: Dos Características Fundamentales

UBICACIÓN

Todo tiene una **posición** en el espacio-tiempo

La ubicación puede usarse para hacer **mejores predicciones**

RELACIÓN

La ubicación permite **entender las relaciones** entre observaciones

Contextualizar datos y **construir vínculos**

Primera Ley de la Geografía

(Waldo Tobler)

"Las cosas cercanas tienden a estar más relacionadas que las cosas distantes"

→ Contextualizamos nuestros datos

→ Construimos vínculos dentro y fuera de los datos

→ Mejoramos nuestros modelos predictivos

El Problema de la Representación

*"Todos los **modelos** están **equivocados**,*
pero algunos son
***útiles**"*

— George Box (estadístico)

*"Todos los **mapas** están **equivocados**,*
pero algunos son
***útiles**"*

— Keith Ord (geógrafo)

Terminología Clave

MODELO DE DATOS

Cómo representamos **conceptualmente** un proceso geográfico

ESTRUCTURA DE DATOS

Como la información geográfica es representada en un computador

La simplificación es NECESARIA y ÚTIL

Complejidad en la Representación

Ejemplo

CÓMO SE MIDE TRADICIONALMENTE

1. Contamos personas en **unidades censales**
2. Dividimos por área total
3. Resultado: densidad como **valor constante** sobre toda la unidad

LA REALIDAD FÍSICA

1. Las personas son **entidades discretas**
2. Cada uno existe en **un punto específico** en espacio-tiempo
3. A escala suficientemente fina:

densidad = 0 en la mayoría de lugares

LA PARADOJA DE ESCALA Y AGREGACIÓN

Medimos agregadamente (**por áreas**), pero el fenómeno es **puntual y discreto**. La densidad 'constante' es una **simplificación necesaria** que oculta variación interna.

Ejemplo: Densidad Poblacional

La dimensión temporal y espacial

LAS PERSONAS SE MUEVEN EN EL TIEMPO

Una persona típica en su día: **Casa → Trabajo → Supermercado → Casa**

Cada ubicación tiene **diferentes densidades en diferentes momentos**

EJEMPLO: MALL

Residentes permanentes:
≈ 0 personas

Sábado 3 PM:
Miles de personas

La densidad es **variable en tiempo y espacio**, pero la medimos como **constante estática**

Representaciones Conceptuales

Los Tres Modelos Fundamentales

OBJETOS • CAMPOS • REDES

1. OBJETOS

DEFINICIÓN

Entidades **discretas** que ocupan una **posición específica** en espacio y tiempo

EJEMPLOS

- Una persona
- Una casa o edificio
- Una unidad censal
- Un país

CARACTERÍSTICAS

- Discontinuos
- Tienen límites claros
- Posición definida

2. CAMPOS

DEFINICIÓN

Un campo geográfico es una función continua que asigna un valor a cada punto del espacio geográfico. Matemáticamente: **f: (x, y) → v**, donde todo punto del espacio tiene exactamente un valor asociado.

EJEMPLOS

- Temperatura
- Elevación del terreno
- Densidad poblacional
- Contaminación del aire

CARACTERÍSTICAS

- Continuos en el espacio
- No tienen límites discretos
- Valores medibles en cualquier punto

Un buen ejemplo es http://hint.fm/wind/

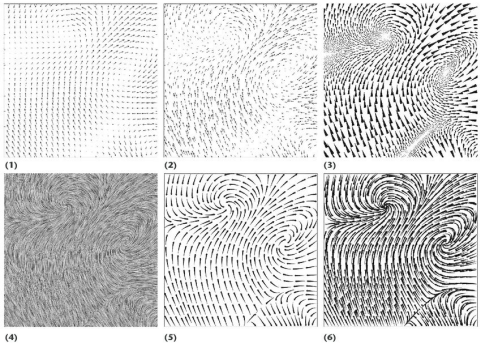

Visualización de Campos vectoriales.

R. Moorhead, P. Rheingans, C. Johnson, T. S. Yoo, H. Pfister and T. Munzner, "Visualization Research Challenges: A Report Summary," in Computing in Science & Engineering, vol. 8, no. , pp. 66-73, 2006.

3. REDES

DEFINICIÓN

Una **red geográfica** es una estructura de datos compuesta por **nodos** y **aristas** georreferenciados, vinculados topológicamente, que permite modelar y analizar relaciones de conectividad y flujo en el espacio geográfico.

EJEMPLOS

- Calles y rutas
- Transporte público
- Redes sociales espaciales
- Conexiones entre estaciones

CARACTERÍSTICAS

- **Topología**: estructura de conexiones
- Distancia física ≠ distancia en la red

Ejemplo: Metro de Santiago - dos estaciones lejanas físicamente pueden estar conectadas directamente

Representaciones Computacionales

Estructuras de Datos

Del concepto al computador

TABLAS GEOGRÁFICAS

Para qué: Almacenar información sobre **objetos discretos**

ESTRUCTURA

Filas = objetos individuales

Columnas = atributos

Columna especial = **geometría**

La geografía es 'un atributo más'

EN PYTHON

GeoDataFrame

(GeoPandas)

Ventaja: Aprovecha toda la infraestructura de bases de datos

SUPERFICIES Y CUBOS

Para qué: Registrar mediciones de **campos continuos**

ESTRUCTURA

Matrices/arrays uniformes

Filas y columnas = **ubicaciones**

Valores de celda = información

Múltiples arrays = **cubos de datos**

EJEMPLOS

- Imágenes satelitales
- Modelos de elevación
- Mapas de temperatura

Múltiples 'bandas' o capas

Representan continuidad en el espacio y (potencialmente) tiempo

GRAFOS ESPACIALES

Para qué: Capturar **relaciones entre objetos** mediadas por el espacio

ESTRUCTURA

Nodos = objetos/ubicaciones

Aristas = **relaciones espaciales**

Matriz de adyacencia

Codifican topologías

EN PYTHON

- **networkX**
  (grafos generales)
- **pysal**
  (pesos espaciales)

Basados en matrices dispersas de scipy

NOMBRES ALTERNATIVOS

Matrices de pesos espaciales • Matrices de adyacencia • Redes espaciales

Enfoque Tradicional

CAMPOS → Rasters (imágenes)

OBJETOS → Vectores (tablas)

REDES → Construidas sobre relaciones

Origen: ARC/INFO (ESRI, años 80-90) ⟶ QGIS, ArcGIS

⚠️ **Esta categorización está cambiando**

¿Por qué está cambiando?

1. Machine Learning y cambios de soporte

- Algoritmos eficientes para traducir entre representaciones
- Menor costo de cambiar entre estructuras
- Predicción > Explicación

2. Búsqueda de Representaciones Universales

- Uber H3 (hexágonos jerárquicos)
- Google S2 (división en celdas cuadradas anidadas de distintas resoluciones, desde el tamaño de un continente hasta el de una habitación)
- WorldPop (Proyecto de investigación que trata a la población como raster mundial, si fuera **temperatura o lluvia** — algo que varía gradualmente en el espacio y que puede medirse en cualquier punto.)

https://www.worldpop.org/

Pregunta de Reflexión

*Si todos los mapas son '**incorrectos**' pero algunos son **'útiles'**,¿cómo decidimos cuál representación usar en un proyecto real?*

La respuesta depende de:

- El **proceso** que queremos capturar
- El **objetivo analítico**
- Los **datos disponibles**
- A veces necesitamos múltiples representaciones

Algunas Fuentes de Datos para sus Proyectos

Censo 2017

URL
http://www.censo2017.cl/microdatos/
Granularidad
manzana (también disponible a nivel de persona)
Frecuencia
10 años
Información geográfica
https://github.com/diegocaro/chile_census_2017_shapefiles
Fácil de obtener y de procesar, aunque más bien se utiliza para **complementar** otros datasets.

Encuestas Origen-Destino

URL
https://www.sectra.gob.cl
Granularidad
personas por hogar (representativa a nivel comunal)
Frecuencia
10 años... con suerte
Información geográfica
Posiciones de origen y destino de viajes
Rica en características de las personas y de sus rutinas. Sin embargo, algunas de sus mediciones ya están obsoletas. Además es difícil de encontrar en formatos abiertos o no propietarios.

Estadísticas Oficiales

URL
https://www.ine.gob.cl/
Granularidad
Múltiples (desde encuestas individuales hasta estadísticas comunales, regionales y a nivel país)
Frecuencia
Depende de la estadística
Información geográfica
Usualmente a nivel de unidad administrativa
Datos de múltiples temáticas que pueden complementar bien otros datasets.

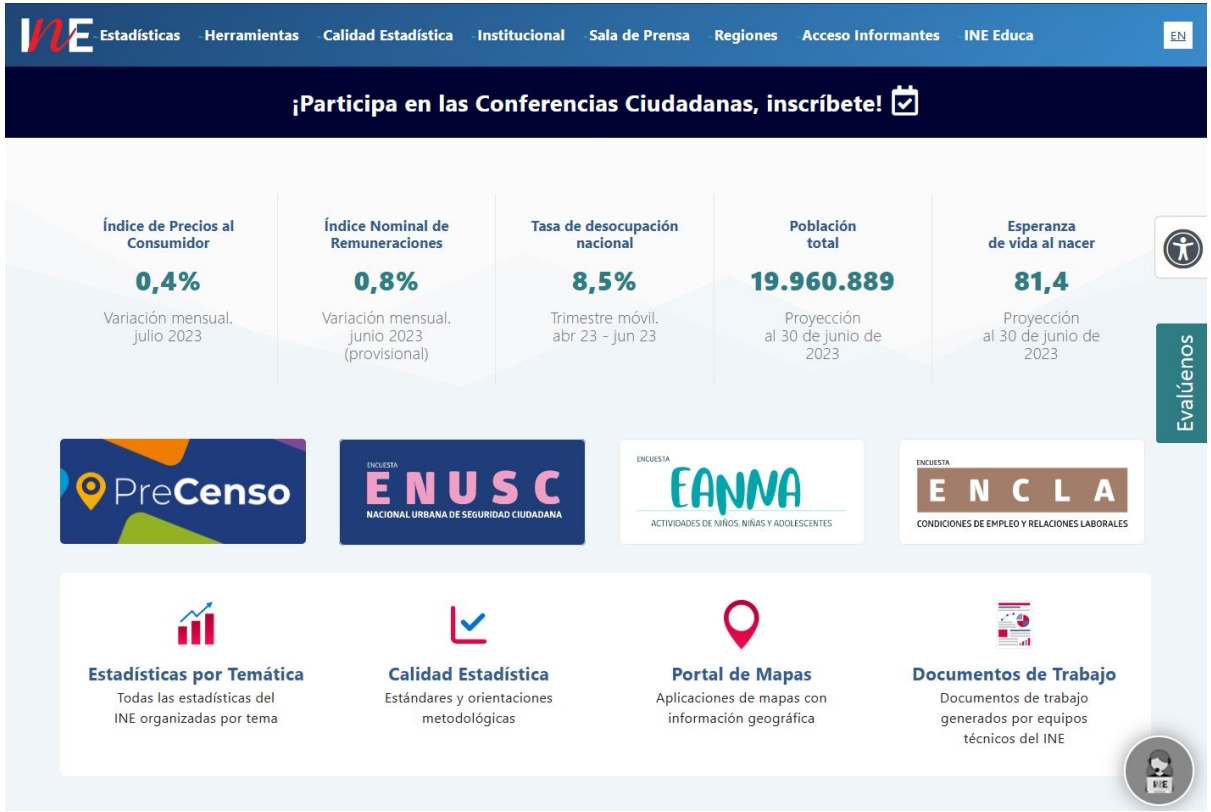

Uso de transporte público en Santiago

URL
https://www.dtpm.cl/index.php/documentos/matrices-de-viaje
Granularidad
Individual (tarjeta bip) y agregado (paraderos, comunas)
Frecuencia
Días de una o dos semanas de cada año, 2011 a 2023
Información geográfica
Coordenadas de paraderos
Aunque le falta consistencia y coherencia (tiene múltiples errores y falta de documentación), es un dataset valioso para entender el uso del transporte público en Santiago

Matrices de Viaje

Matrices origen-destino, subidas y bajadas, a partir de software ADATRAP desarrollado por Universidad de Chile – Directorio de Transporte Público Metropolitano.

Las matrices origen-destino (OD) de viajes en transporte público (Buses Transantiago y Metro), así como la información de subidas y bajadas, fueron obtenidas de las bases de datos de la tarjeta bip! y de los GPS de los buses, mediante el software ADATRAP (Análisis de Datos de Transporte Público) a partir de metodologías desarrollada en conjunto por la Universidad de Chile y el Directorio de Transporte Público Metropolitano (DTPM).

Las bases de datos disponibles respecto al último corte temporal son los siguientes:

- Tabla de viajes. Cada fila de la base de datos, corresponde a un viaje realizado por una persona, en donde es estimado el lugar de subida y bajada de cada etapa de viajes. Se incluyen archivos que detallan los campos y estructuras de las tablas.
- Tabla de etapas. Es un extracto de la Tabla de Viajes, donde cada fila de la base de datos corresponde a una etapa del viaje realizado por una persona, en donde es estimado el lugar de subida y bajada de la etapa. Se incluyen archivos que detallan los campos y estructuras de las tablas.
- Tablas agregadas de matrices OD, subidas y bajadas. Contienen un resumen de la información de las tablas de viajes y etapas.

Al respecto, cabe hacer notar:

- La información de la tabla de viajes, tabla de etapas y tablas agregadas de matrices OD, subidas y bajadas, no tienen información de viajes no registrados mediante la tarjeta bip! (evasión).
- Esta metodología está en constante mejoramiento, por lo que puede haber nuevas versiones a futuro.
- Para efectos de las matrices OD, los criterios para determinar qué conjunto de etapas forma un viaje son parte de la metodología desarrollada y no corresponden únicamente a las reglas de pago.
- A partir de abril 2017 la información es estimada por día. Los cortes anteriores se obtuvieron a nivel semanal.

Seguridad de Tránsito

URL
https://mapas-conaset.opendata.arcgis.com/
Granularidad
Accidente y agregado por comuna
Frecuencia
Anual
Información geográfica
Coordenadas de accidentes
Es un dataset poco explorado pero que parece rico en características. Tiene un visualizador geográfico que permite explorarlos antes de descargar (algo poco frecuente en Chile).

Próximos Pasos

PRÓXIMAS CLASES

- Herramientas computacionales
- Trabajaremos con **GeoPandas y otras bibliotecas relacionadas**
- Ejercicios prácticos aplicando conceptos

¡Gracias!

Pensamiento Geográfico para Científicos de Datos

Análisis de Datos Espaciales - Sesión 0