

Análisis de Datos Espaciales

Clase 04: Autocorrelación Espacial Global

Daniela Opitz

Departamento de Informática
Universidad Técnica Federico Santa María

2026


¿Qué es Autocorrelación Espacial?

¿Existe una relación entre el valor de una variable en una ubicación y los valores de la misma variable en ubicaciones vecinas?

- **Autocorrelación espacial positiva:**
valores similares se agrupan (clustering).
- **Autocorrelación espacial negativa:**
valores distintos se alternan (dispersión).
- **Aleatoriedad espacial:**
sin patrón espacial.

Ejemplo: Referéndum UE 2016

% Votos Leave — Referéndum UE 2016



¿hay un patrón espacial?

% votos Leave (abandonar la UE) por territorio.

Rezago Espacial (Spatial Lag)

El rezago espacial Y_{sl} calcula un promedio ponderado de los valores de los vecinos y se puede expresar de la siguiente manera:

$$Y_{sl} = W \times Y$$

, donde **W** es la matriz de pesos espaciales (define la vecindad) e **Y** es el vector de valores observados.

Permite comparar el valor de cada unidad con el promedio de su vecindario. Es la base de todos los estadísticos de autocorrelación.

Rezago Espacial (Spatial Lag)

	lad16nm	geometry	Pct_Leave
lad16cd			
E06000001	Hartlepool	MULTIPOLYGON (((−141402.215 7309092.065, −1537...	69.57
E06000002	Middlesbrough	MULTIPOLYGON (((−136924.099 7281563.141, −1426...	65.48
E06000003	Redcar and Cleveland	MULTIPOLYGON (((−126588.382 7293641.928, −1260...	66.19
E06000004	Stockton-on- Tees	MULTIPOLYGON (((−146690.634 7293316.144, −1537...	61.73
E06000010	Kingston upon Hull, City of	MULTIPOLYGON (((−35191.009 7134866.244, −39368...	67.62

Rezago Espacial (Spatial Lag)

Datos: % voto Leave y vecindades

Área	% Leave	Vecinas
A	70%	B, C
B	65%	A, D
C	30%	A, D
D	35%	B, C

Vecindad tipo reina/torre: cada área comparte lado con otras dos.

nota: la tabla es una simplificación con fines educativos, los vecinos y los valores no son reales

Rezago Espacial

Vector γ (% Leave)

A	70
B	65
C	30
D	35

Un número por área: 4 filas $\times$ 1 columna.

Matriz de pesos W (estandarizada por filas)

	A	B	C	D
A	0	0.5	0.5	0
B	0.5	0	0	0.5
C	0.5	0	0	0.5
D	0	0.5	0.5	0

Cada peso = $1/(\text{n}^\circ \text{ de vecinas}) = 1/2 = 0.5$. Diagonal = 0.

Rezago Espacial

$$W \times Y = Y_{sl}$$



0	0.5	0.5	0
0.5	0	0	0.5
0.5	0	0	0.5
0	0.5	0.5	0

70
65
30
35

$\frac{1}{2}(65) + \frac{1}{2}(30) = 47.5$
$\frac{1}{2}(70) + \frac{1}{2}(35) = 52.5$
$\frac{1}{2}(70) + \frac{1}{2}(35) = 52.5$
$\frac{1}{2}(65) + \frac{1}{2}(30) = 47.5$

Rezago Espacial

% Leave original vs. su rezago espacial — el rezago suaviza las diferencias.



Caso Binario: Join Counts

Primero convertimos la variable a binaria:
asignamos 1 a los territorios donde Leave superó el 50%, y 0 al resto.


Luego contamos los tipos de uniones entre vecinos:

BB: ambos Leave


WW: ambos Remain

BW: uno de cada tipo

Si hay autocorrelación positiva, esperamos más uniones BB y WW que bajo aleatoriedad.




Join Counts



Inferencia: Pseudo p-valor



Distribución de bb en las 999 permutaciones (valores reales PySAL)



Solo 6 permutaciones tienen $bb \geq 20$

$$p = (6 + 1) / (999 + 1) = 0.007 \checkmark$$

Moran Plot

Scatterplot de la variable centrada (z_i) vs. su rezago espacial (Wz_i).

Cuatro cuadrantes:


HH: alto-alto (clustering alto)

LL: bajo-bajo (clustering bajo)

HL: alto-bajo (outlier espacial)

LH: bajo-alto (outlier espacial)

La pendiente de la recta de regresión es el I de Moran.



Recordemos: Pendiente OLS

La pendiente de la recta de regresión se calcula como:

$$\beta = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Donde:


x_i valor de la observación i en X

$\bar{x}$ media de todos los valores de X

$(x_i - \bar{x})$ desviación de la obs. i respecto a la media

y_i valor correspondiente en Y para la obs. i

$(y_i - \bar{y})$ desviación de la obs. i en Y respecto a su media



I de Moran = Pendiente de Regresión

La fórmula de la pendiente (OLS) es:

$$\beta = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Si $x_i = z_i$ (variable centrada) y $y_i = Wz_i$ (rezago espacial). Sustituyendo:

$$\beta = \Sigma_i z_i \cdot Wz_i / \Sigma_i z_i^2$$

Y como $Wz_i = \Sigma_j w_{ij} z_j$, expandiendo se obtiene:

$$\beta = \Sigma_i \Sigma_j w_{ij} z_i z_j / \Sigma_i z_i^2 = \text{I de Moran}$$

Válido cuando W está centrada por filas, en cuyo caso $n / \Sigma_i \Sigma_j w_{ij} = 1$ y el factor de escala desaparece.

I de Moran: Cada Término

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} z_i z_j}{\sum_i z_i^2}$$

Término

n

$S_o = \sum_i \sum_j w_{ij}$

$z_i = y_i - \bar{y}$

w_{ij}

$\sum_i \sum_j w_{ij} z_i z_j$

$\sum_i z_i^2$

Significado

Número de unidades espaciales (ej: distritos)

Suma de todos los pesos (factor de escala)

Desviación del valor observado respecto a la media global

Peso espacial entre las unidades i y j (0 si no son vecinos)

Numerador: covariación espacial ponderada entre vecinos

Denominador: varianza total de la variable (sin el 1/n)

I de Moran: Significado

Para variables continuas. Cada área se compara con la media global; luego se multiplican las desviaciones entre vecinos.

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} z_i z_j}{\sum_i z_i^2}$$

donde $\mathbf{z}_i = \mathbf{y}_i - \bar{\mathbf{y}}$



$(+) \times (+) = \text{positivo} \rightarrow \text{similares}$

$(-) \times (-) = \text{positivo} \rightarrow \text{similares}$

$(+) \times (-) = \text{negativo} \rightarrow \text{distintos}$

$I \approx +1 \rightarrow \text{clustering}$ $I \approx 0 \rightarrow \text{aleatorio}$ $I \approx -1 \rightarrow \text{dispersión}$

I de Moran: Inferencia



Se compara el valor observado contra 999 permutaciones aleatorias. $I = 0.645$, $p = 0.001$.

C de Geary

Compara pares de vecinos directamente, sin pasar por la media global.

$$C = \frac{n-1}{2 \sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (y_i - y_j)^2}{\sum_i (y_i - \bar{y})^2}$$

Usa la diferencia al cuadrado entre vecinos.

C ≈ 0 → vecinos similares (clustering)

C ≈ 1 → aleatorio

C ≈ 2 → vecinos distintos (dispersión)

Más sensible a diferencias locales que Moran.

C de Geary — cálculo paso a paso

$$C = \frac{n-1}{2 \sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (y_i - y_j)^2}{\sum_i (y_i - \bar{y})^2}$$

Numerador: $\sum_{i,j} w_{ij} (y_i - y_j)^2$

Par	$(y_i - y_j)^2$	w_{ij}	producto
A-B	$(70 - 65)^2 = 25$	0.5	12.5
A-C	$(70 - 30)^2 = 1600$	0.5	800.0
B-A	$(65 - 70)^2 = 25$	0.5	12.5
B-D	$(65 - 35)^2 = 900$	0.5	450.0
C-A	$(30 - 70)^2 = 1600$	0.5	800.0
C-D	$(30 - 35)^2 = 25$	0.5	12.5
D-B	$(35 - 65)^2 = 900$	0.5	450.0
D-C	$(35 - 30)^2 = 25$	0.5	12.5

$$\sum_{i,j} w_{ij} (y_i - y_j)^2 = 2550$$

Denominador y resultado

$$\bar{y} = (70 + 65 + 30 + 35) / 4 = 50$$

Desviaciones: $z_i \in \{+20, +15, -20, -15\}$

$$\sum_i (y_i - \bar{y})^2 = 400 + 225 + 400 + 225 = 1250$$

$$n = 4, \quad \sum_i \sum_j w_{ij} = 4$$

$$C = \frac{3}{2 \cdot 4} \cdot \frac{2550}{1250}$$

$$C = 0.375 \times 2.04 = 0.765$$

$C = 0.765 < 1$ sugiere vecinos más parecidos que bajo aleatoriedad. (Con la misma tabla, $I_{\text{Moran}} = -0.02$: distintos índices miden aspectos distintos.)

G de Getis-Ord

A diferencia de Moran y Geary, G no mide clustering de valores similares en general, sino concentración específica de valores altos o bajos.

$$G(d) = \frac{\sum_i \sum_j w_{ij}(d) y_i y_j}{\sum_i \sum_j y_i y_j}$$

G alto y significativo: concentración de valores ALTOS (hot spots).

G bajo y significativo: concentración de valores BAJOS (cold spots).

Es el único de los tres que distingue hot spots de cold spots.

Comparación de Índices

Índice	Qué mide	Rango	Interpretación
Moran's I	Similitud global con vecinos	$[-1, +1]$	+1 = clustering 0 = aleatorio -1 = dispersión
Geary's C	Diferencia directa entre vecinos	$[0, 2]$	0 = clustering 1 = aleatorio 2 = dispersión
Getis-Ord G	Concentración de valores altos/bajos	depende	G alto = hot spots G bajo = cold spots

Los tres se evalúan con permutaciones espaciales (pseudo p-valor).

Resumen

- La autocorrelación espacial mide si los valores cercanos se parecen más (o menos) de lo esperado por azar.
- Join Counts para variables binarias; Moran, Geary y G para variables continuas.
- La significancia se evalúa con permutaciones espaciales (pseudo p-valor).
- Moran's I es el más usado y tiene una representación gráfica útil (Moran Plot).
- Geary's C es más sensible a diferencias locales entre vecinos.
- Getis-Ord G detecta hot spots (valores altos) y cold spots (valores bajos).