

Análisis de Datos Espaciales

Clase 05: Autocorrelación Espacial Local



Daniela Opitz

Departamento de Informática
Universidad Técnica Federico Santa María

2026

Recordatorio: Clase 04


- Rezago espacial
- Join Counts (binarias)
- I de Moran (continuas)
- C de Geary (continuas)
- G de Getis-Ord (hot/cold)




Estadísticos Locales

Un estadístico global resume todo el mapa en un único número.

Global — 1 número para todo el mapa



Local — 1 valor por observación (n valores)




Autocorrelación Espacial Local (LISA)

LISA = *Local Indicators of Spatial Association*.

Un estadístico por cada observación.
En vez de un único número, obtenemos
n valores que se pueden mapear.

Permite responder:

- ¿Dónde están los hot spots?
- ¿Dónde están los cold spots?
- ¿Hay outliers espaciales?
- ¿Qué áreas son significativas?



Global vs. Local

Aspecto	Estadísticos globales	Estadísticos locales (LISA)
Nº de valores	1 para todo el mapa	1 por observación (n valores)
Pregunta	¿Hay clustering?	¿Dónde y de qué tipo?
Salida típica	Un estadístico + p-valor	Un mapa de categorías
Ejemplos	I Moran, C Geary, G Getis-Ord	I_i , G_i , G_i^*


Brexit

% votos Leave por territorio

- n = 380 territorios
- W = KNN(k = 8), centrada por filas.

lad16cd	lad16nm	geometry	Pct_Leave
E06000001	Hartlepool	MULTIPOLYGON (((−141402.215 7309092.065, −1537...	69.57
E06000002	Middlesbrough	MULTIPOLYGON (((−136924.099 7281563.141, −1426...	65.48
E06000003	Redcar and Cleveland	MULTIPOLYGON (((−126588.382 7293641.928, −1260...	66.19
E06000004	Stockton-on- Tees	MULTIPOLYGON (((−146690.634 7293316.144, −1537...	61.73
E06000010	Kingston upon Hull, City of	MULTIPOLYGON (((−35191.009 7134866.244, −39368...	67.62

% Votos Leave — Referéndum UE 2016




Punto de partida: el gráfico de Moran


Scatterplot de z_i (valor centrado)
vs. Wz_i (rezago espacial).

Cada punto del scatterplot cae en uno de cuatro cuadrantes. Cada cuadrante tiene una interpretación geográfica específica.

Idea LISA: pintar cada polígono del mapa con el color de su cuadrante.



Los cuatro cuadrantes



Interpretación de los cuadrantes

Código	z _i	W z _i	Nombre	Significado
HH	alto	alto	hot spot	Alto rodeado de alto → cluster positivo
LL	bajo	bajo	cold spot	Bajo rodeado de bajo → cluster positivo
LH	bajo	alto	doughnut	Outlier: bajo rodeado de alto
HL	alto	bajo	diamond	Outlier: alto rodeado de bajo

HH + LL = autocorrelación positiva. LH + HL = outliers espaciales.

I de Moran Local (I_i)

Para cada observación i calculamos:

$$I_i = \frac{z_i}{m_2} \sum_j w_{ij} z_j \quad \text{con} \quad m_2 = \frac{\sum_i z_i^2}{n}$$

$z_i = y_i - \bar{y}$ valor centrado (desviación respecto a la media)

w_{ij} peso espacial entre i y j

I de Moran Local (I_i)

El I de Moran global se puede escribir como un promedio ponderado de los I de Moran locales:

$$I = \frac{1}{S_0} \sum_i I_i \quad \text{con} \quad S_0 = \sum_i \sum_j w_{ij}$$

, donde $S_0 = \sum_i \sum_j w_{ij}$ es la suma de todos los pesos espaciales, i indexa la observación (área) para la que se calcula el estadístico y j recorre las demás áreas del mapa.

No son estadísticos separados: el global es el promedio de los locales. Lo que hacemos al pasar a LISA es abrir la caja negra del global.

¿Para qué I_i si ya tengo los cuadrantes?

Cuadrante (signo de z_i y Wz_i)

- Tipo de patrón: HH / LL / LH / HL
- Define el color del mapa
- No dice cuán fuerte es el patrón
- No se puede testear por sí solo

I_i

- Magnitud: cuán fuerte es el patrón
- Permite ranking entre áreas
- Test de permutaciones → **pseudo p-valor**

Ejemplo I_i

Vector γ (% Leave)

A	70
B	65
C	30
D	35

Un número por área: 4 filas $\times$ 1 columna.

Matriz de pesos W (estandarizada por filas)

	A	B	C	D
A	0	0.5	0.5	0
B	0.5	0	0	0.5
C	0.5	0	0	0.5
D	0	0.5	0.5	0

Cada peso = $1/(\text{n}^\circ \text{ de vecinas}) = 1/2 = 0.5$. Diagonal = 0.

Ejemplo I_i

I de Moran local — reutiliza el rezago de clase 04

Área	y _i	$\bar{y}$ (media de y)	Y _{sl,i}	z _i	Wz _i	I _i	Cuadrante
A	70	50	47.5	+20	-2.5	-0.16	HL
B	65	50	52.5	+15	+2.5	+0.12	HH
C	30	50	52.5	-20	+2.5	-0.16	LH
D	35	50	47.5	-15	-2.5	+0.12	LL

Paleta estándar del mapa LISA



HH (hot spot)




LL (cold spot)



LH (doughnut)



HL (diamond)



No significativo



Colores fuertes (rojo, azul) → clusters puros (HH, LL).

Colores intermedios (celeste, naranja) → outliers espaciales (LH, HL).

Gris → no significativo ($p \geq 0.05$).

Mapa LISA del % voto Leave (Brexit)

Mapa LISA — I de Moran local del % Leave ($p < 0.05$)



Significancia: permutaciones espaciales

La idea es la misma que en el I global, pero aplicada a cada área:

1. Se fija la geometría (polígonos y W no cambian).
2. Se permutan los valores de y entre las áreas (999 veces).
3. Para cada permutación se recalcula I_i .
4. Se construye la distribución de referencia bajo aleatoriedad.
5. El pseudo p-valor es la proporción de permutaciones con I_i tan o más extremo que el observado.

Umbral típico: **$p < 0.05$** .

Getis-Ord Local: G_i y G_i^*

Versión local del G: concentración de valores altos o bajos en el entorno de cada área.

$$G_i = \frac{\sum_{j \neq i} w_{ij} y_j}{\sum_{j \neq i} y_j}$$


$$G_i^* = \frac{\sum_j w_{ij} y_j}{\sum_j y_j}$$

G_i excluye el sitio focal i de la suma


G_i^* incluye el sitio focal i en su propio vecindario

G_i vs. G_i^* — qué entra al cálculo

G_i — excluye el sitio focal



G_i^* — incluye el sitio focal



Cuando el valor focal y_i es alto, G_i^* sube más que G_i .
Cuando y_i es bajo, G_i^* baja más que G_i .

Ejemplo numérico: G_i vs G_i^*

G_i vs. G_i^* — cálculo paso a paso

Área	y_i (% Leave)	Vecinas	G_i (sin i)	G_i^* (con i)	$G_i^* - G_i$
A	70%	B, C	0.73	0.83	+0.10
B	65%	A, D	0.78	0.85	+0.07
C	30%	A, D	0.62	0.68	+0.06
D	35%	B, C	0.58	0.65	+0.07

G_i^* incluye y_i en el numerador y denominador. El cociente sube cuando y_i suma al vecindario (áreas A, B).


Cómo clasificar hot spot / cold spot con G_i^*

z-score	p-valor	Clasificación	Intuición
$z > 0$	$p < 0.05$	Hot spot	vecindario concentra valores ALTOS
$z < 0$	$p < 0.05$	Cold spot	vecindario concentra valores BAJOS
cualquiera	$p \geq 0.05$	No significativo	el patrón puede ser producto del azar

Moran local vs. Getis-Ord local


I de Moran local (LISA)

Mapa LISA — I de Moran local del % Leave ($p < 0.05$)



Gi* de Getis-Ord local

Hot spots y cold spots del % Leave (G_i^* , $p < 0.05$)



I de Moran local vs. Getis-Ord local

	I_i (Moran local)	G_i^* (Getis-Ord local)
¿Qué detecta?	HH, LL, LH, HL	Hot spots y cold spots
¿Distingue outliers?	Sí (LH y HL)	No
Uso típico	Análisis exploratorio completo	Focos: salud, crimen, epidemias

Resumen

- Los LISA descomponen el estadístico global en n valores locales (uno por observación).
- El I de Moran local clasifica cada área en HH, LL, LH o HL según el cuadrante del gráfico de Moran.
- La significancia se evalúa con permutaciones (999 mapas aleatorios, umbral $p < 0.05$).
- El mapa LISA combina cuadrante y significancia con una paleta estándar.
- Getis-Ord local (G_i , G_i^*) detecta hot y cold spots pero no outliers.

Referencias

- Anselin, L. (1995). Local Indicators of Spatial Association — LISA. *Geographical Analysis*, 27(2), 93–115.
- Getis, A., & Ord, J. K. (1992). The Analysis of Spatial Association by Use of Distance Statistics. *Geographical Analysis*, 24(3), 189–206.
- Fotheringham, A. S. (1997). Trends in quantitative methods I: stressing the local. *Progress in Human Geography*, 21(1), 88–96.
- Nelson, T. A., & Boots, B. (2008). Detecting spatial hot spots in landscape ecology. *Ecography*, 31(5), 556–566.
- Rey, S. J., Arribas-Bel, D., & Wolf, L. J. (2023). *Geographic Data Science with Python*. Cap. 7.