

Análisis de Datos Espaciales

Clase 07: Regionalizacion

Daniela Opitz


Departamento de Informática
Universidad Técnica Federico Santa María
2026

Pregunta de Hoy


Si tenemos muchas variables sobre cada unidad territorial **¿cómo agrupamos en grupos coherentes?**

Dos Formas de Agrupar

Clustering — agrupa por similitud
(fragmentos por todo el mapa)



Regionalización — similitud + contigüidad
(regiones conexas)



¿Cuándo usar cada uno?

Clustering (no espacial) — para CLASIFICAR variables:


- Tipologías de barrios o comunas (perfiles socioeconómicos).
- Segmentación de clientes / usuarios.
- Análisis exploratorio de qué tan parecidas son las unidades.

Regionalización (espacial) — para DELIMITAR REGIONES:

- Distritos electorales, áreas de gestión, zonas de servicios.
- Cuencas hidrográficas, áreas de manejo forestal.
- Cualquier unidad operativa que necesite ser geográficamente coherente.

Caso: census tracts de San Diego

628 unidades territoriales $\times$ 9 variables socioeconómicas



Caso: census tracts de San Diego

db.head() — primeras 5 filas


GEOID	median_house_value	pct_white	median_age	geometry
06073018300	732900.00	0.92	37.10	POLYGON ((-13069450.12 3922380.7...
06073018601	473800.00	0.79	41.20	POLYGON ((-13067719.77 3922939.4...
06073017601	930600.00	0.88	54.40	POLYGON ((-13058166.11 3907247.6...
06073019301	478500.00	0.80	42.30	POLYGON ((-13056896.29 3925255.6...
06073018700	515570.90	0.75	21.80	POLYGON ((-13090788.51 3946435.4...

Variables que Vamos a Agrupar


- **median_house_value** — valor mediano de la vivienda
- **pct_white** — % de población blanca
- **pct_rented** — % de viviendas arrendadas
- **pct_hh_female** — % de hogares con jefatura femenina
- **pct_bachelor** — % con título universitario
- **median_no_rooms** — n° mediano de habitaciones
- **income_gini** — Gini del ingreso dentro del tract
- **median_age** — edad mediana
- **tt_work** — tiempo medio de viaje al trabajo

¿Estructura espacial en estas variables?


Valor mediano de la vivienda (USD)




% Población blanca




% Viviendas arrendadas




% Hogares con jefatura femenina




% Personas con título universitario




Nº mediano de habitaciones




Gini del ingreso (intra-tract)



Edad mediana



Tiempo de viaje al trabajo



Moran's I Confirma Autocorrelación Espacial

Moran's I de cada variable (matriz Queen, 999 permutaciones)

Variable	Moran's I	p-valor
<code>median_house_value</code>	0.647	0.001
<code>pct_white</code>	0.602	0.001
<code>pct_rented</code>	0.451	0.001
<code>pct_hh_female</code>	0.282	0.001
<code>pct_bachelor</code>	0.433	0.001
<code>median_no_rooms</code>	0.539	0.001
<code>income_gini</code>	0.295	0.001
<code>median_age</code>	0.381	0.001
<code>tt_work</code>	0.103	0.003

Las 9 variables tienen Moran's I positivo y significativo ($p = 0.001$) — regionalizar tiene sentido.

Estandarización

Los métodos usan **distancias** entre observaciones.

Si ***median_house_value*** se mide en miles (USD) y **income_gini** está entre 0 y 1, la primera dominará. Por eso siempre se estandariza.

$$x_i^{\text{esc}} = \frac{x_i - \text{mediana}(x)}{Q_{75}(x) - Q_{25}(x)}$$

robust_scale: usa MEDIANA e IQR — más robusto a outliers que el z-score.

K-Means

Datos




n observaciones, sin etiqueta

Inicialización




k centroides al azar

Asignación



cada punto a su centroide más cercano

Convergencia



centroides estables

K-Means minimiza la varianza interna (WCSS)


$$\text{WCSS} = \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \mu_c\|^2$$

Donde:

- k** — número de clusters elegido (acá k=5).
- c** — índice del cluster (1, 2, ..., k).
- C_c** — conjunto de observaciones asignadas al cluster c.
- x_i** — vector de variables estandarizadas de la observación i.
- μ_c** — centroide del cluster c (promedio de las x_i).
- || · ||²** — distancia euclidiana al cuadrado.

Cuanto MENOR el WCSS, más homogéneos los grupos.

K-Means con $k=5$ sobre San Diego



Resultado:


Los clusters están geográficamente fragmentados. Un mismo color aparece en zonas inconexas del mapa.

Es lo esperado: K-Means agrupa por similitud de atributos, **no por geografía.**

Clustering Aglomerativo Jerárquico (AHC)


Clustering jerárquico aglomerativo

Clusters: {A}{B}{C}{D}{E}{F}



Paso 0: cada punto es su propio cluster

Dendrograma



Empieza con cada punto como su propio cluster. En cada paso, une los DOS más cercanos. Cortando el dendrograma se obtienen k grupos.

Criterios de Unión

- Cuando dos clusters tienen más de un punto, hay que decidir cómo medir la distancia entre ellos. Esta decisión se llama **criterio de unión** y cambia los resultados del algoritmo.
- Hay cuatro criterios:
 - **Single** — distancia entre los puntos **más cercanos** de cada cluster. Forma clusters alargados, encadenados. Útil para formas irregulares.
 - **Complete** — distancia entre los puntos **más lejanos** de cada cluster. Forma clusters compactos. Sensible a outliers.
 - **Average** — **promedio** de las distancias entre todos los pares de puntos. Punto medio entre single y complete.
 - **Ward** — fusiona los clusters que producen el **menor aumento de la varianza interna**. Forma clusters compactos y balanceados.

Criterios de Union (Ward)

$$\Delta(A, B) = \frac{|A| |B|}{|A| + |B|} \|\bar{x}_A - \bar{x}_B\|^2$$


Donde:

- **A, B** : dos clusters candidatos a fusionarse.
- **|A|, |B|** : número de observaciones en cada cluster.
- $\bar{x}_A$: centroide de A (promedio)
- $\bar{x}_B$: centroide de B (promedio)
- **$\Delta(A,B)$** : incremento de varianza interna si fusionamos A y B.

Ward elige fusionar el par con Δ más pequeño $\rightarrow$ clusters compactos.

AHC (Ward) con $k=5$ sobre San Diego

AHC (Ward) con 5 clusters



Igual de fragmentado que K-Means.

El patrón es algo más limpio, pero los clusters siguen apareciendo en varias zonas inconexas.

AHC tampoco impone restricción geográfica. Sigue agrupando solo por similitud.

Agregando Conectividad

- La matriz de pesos define vecindad entre unidades individuales. Al agregar `connectivity` al AHC, el algoritmo solo puede fusionar dos clusters si al menos un miembro de cada uno son vecinos entre sí.
- Esto garantiza que los grupos resultantes sean regiones contiguas.

- **AHC sin restricción:**

```
AgglomerativeClustering(linkage='ward', n_clusters=5)
```


- **AHC con restricción de vecindad:**

```
AgglomerativeClustering(linkage='ward', n_clusters=5,  
connectivity=w.sparse)
```

El parámetro connectivity recibe la matriz de pesos (Queen, Rook, KNN...) y solo permite fusionar clusters vecinos.

Regionalización con Contigüidad

Regionalización: AHC + Queen




Cada grupo es ahora una región contigua.

Los colores ya no se reparten por todo el mapa — ocupan zonas conexas.

Queen = dos tracts vecinos si comparten cualquier punto en su frontera.

Regionalización con K-NN

Regionalización: AHC + KNN ($k=4$)




KNN: cada tract a sus k centroides más cercanos.

Útil cuando hay polígonos de tamaños muy distintos o cuando queremos exactamente el mismo número de vecinos por unidad.


Resultado distinto al de Queen — la elección de la matriz de pesos importa.

Comparación


K-Means (5 clusters)




AHC (Ward) (5 clusters)



Regionalización Queen (5 clusters)



Regionalización KNN (5 clusters)




Evaluación

- Medimos cuán homogéneo es cada grupo en sus variables usando la **suma de cuadrados intra-cluster**.

$$\text{WCSS} = \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \mu_c\|^2$$

- Contamos áreas aisladas



El trade-off: atributos vs. geografía

Método	WCSS (menor = mejor en atributos)	# componentes (menor = mejor en geografía)
K-Means	2516	60
AHC	2680	62
Reg. Queen	3122	5
Reg. KNN	3243	6

Las regionalizaciones pagan en homogeneidad de atributos (WCSS sube) a cambio de coherencia geográfica (componentes baja a 5–6).

¿Cuándo usar cada uno?

- ▶ **Para describir tipos / clasificar perfiles:**

- clustering (K-Means o AHC). *No importa la geografía — interesa la similitud de atributos.*

- ▶ **Para delimitar regiones operativas:**

- regionalización (AHC + connectivity). *Distritos, áreas de gestión, cuencas — necesitan ser conexas.*

No hay método universalmente mejor, depende del USO.

Resumen

- ▶ **Estandarizar siempre**
antes de calcular distancias entre observaciones.
- ▶ **Verificar autocorrelación espacial**
(Moran's I). Si las variables no la tienen, regionalizar tiene poco sentido.
- ▶ **Hay un trade-off**
entre homogeneidad de atributos y contigüidad geográfica.
- ▶ **La matriz de pesos importa**
(Queen, Rook, KNN...). Hay que justificar la elección.