

Análisis de Datos Espaciales

Clase 08: Regresión Espacial Parte 1

Daniela Opitz

Departamento de Informática
Universidad Técnica Federico Santa María

2026

La Pregunta de Hoy


- Hasta ahora describimos datos espaciales: mapas, autocorrelación, clusters, regiones.
- Hoy queremos **explicar una variable a partir de otras.**
- Pero sin perder de vista que las observaciones *están en el espacio*.

Outline

1. Por qué el espacio importa en regresión.
2. Regresión clásica (OLS) — el modelo y cómo se ajusta.
3. Cómo evaluamos el ajuste: R^2 y p-value.
4. Diagnóstico: ¿hay estructura espacial en los residuos?
5. Primera incorporación del espacio: modelo SLX.
6. Siguiendo clase SEM y SAR.

Caso: Airbnb en San Diego

Precio por noche (log USD) — 6.110 propiedades



6.110 propiedades · atributos físicos + ubicación · variable objetivo: log(precio por noche).

¿Por qué el Espacio Importa?

- Una regresión clásica asume errores INDEPENDIENTES entre observaciones.
- Pero en el espacio eso casi nunca se cumple.
- Dos formas en que el espacio entra a la regresión:
 - **Dependencia espacial:** las observaciones se contagian: precios vecinos se parecen.
 - **Heterogeneidad espacial:** los parámetros cambian según la zona (costa vs interior).

Hoy nos enfocamos en la DEPENDENCIA.

Regresión Lineal

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + \varepsilon_i$$

Donde:

- y_i — variable a explicar (en nuestro caso, log_price).
- x_{ik} — k-ésima variable explicativa de la observación i.
- β_0 — intercepto: valor de y cuando todas las x son 0.
- β_k — efecto marginal de x_k , manteniendo el resto fijo.
- ε_i — error: todo lo que no logramos explicar.

Notación que Vamos a Usar

 y_i

OBSERVADO

la y sola (con subíndice)

El valor REAL de la observación i.
Lo que mediste, el dato que te llegó.

log(precio) real de la
propiedad i = 4.6

6.110 valores
(uno por propiedad)

punto navy en el mapa

 $\bar{y}$

PROMEDIO

y barra

El promedio de TODAS las observaciones.
Un solo número, igual para todos.

log(precio) promedio del
dataset ≈ 5.0

1 solo valor
(constante)

línea horizontal punteada

 $\hat{y}_i$

PREDICHO

y gorro / y sombrero

Lo que el MODELO predice para i,
dados sus atributos (x).

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots$$

6.110 valores
(uno por propiedad)

punto naranja sobre la recta


¿Cómo Elegimos los β ? Mínimos cuadrados

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Léase "**arg min**": el valor de β que **produce** el mínimo — no el mínimo en sí, sino el β que lo logra.

- **OLS elige los β que MINIMIZAN la suma de los residuos al cuadrado.**
- Buscamos la combinación lineal que pasa lo más cerca posible de todos los puntos, midiendo "cerca" con la distancia vertical.
- **¿Por qué al cuadrado?** (a) penaliza más los errores grandes; (b) errores positivos y negativos no se cancelan.

¿Qué es la "Distancia Vertical"?



Para cada observación, comparamos el **y observado** con el **y predicho por la recta**, a la MISMA x .

*Esa diferencia es el **residuo** y es lo que OLS minimiza al cuadrado.*


Los Supuestos Clásicos del OLS

Para que OLS sea insesgado y los errores estándar válidos (Gauss-Markov), suponemos sobre ε_i :

1. **Linealidad:** el modelo es lineal en los parámetros.
2. **Media cero:** $E[\varepsilon_i] = 0$.
3. **Homocedasticidad:** varianza constante: $\text{Var}(\varepsilon_i) = \sigma^2$.
4. **INDEPENDENCIA:** $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. *El error de una observación no predice el de otra.*
5. **No multicolinealidad:** perfecta entre las x.

El supuesto (4) es el que va a romperse en datos espaciales y es la motivación de toda esta clase.

¿Qué es la Homocedasticidad?



Homocedasticidad = **MISMA dispersión**. La varianza del error es **CONSTANTE** para todas las observaciones.

*Si la varianza **cambia con x** (heterocedasticidad), los errores estándar del OLS se calculan mal y los t-statistics no son confiables.*

¿Qué tan Bueno es el Ajuste?

Dos métricas básicas: R^2 y p-value


R^2 ¿Cuánta Varianza Explica el Modelo?

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} = 1 - \frac{SSR}{TSS}$$

Componentes:

- **TSS:** Total Sum of Squares = $\sum (y_i - \bar{y})^2$, la varianza total de y.
- **SSR:** Sum of Squared Residuals = $\sum (y_i - \hat{y}_i)^2$, lo que el modelo NO explica.
- **R^2 :** Proporción de la varianza explicada por el modelo. Entre 0 y 1.
- $R^2 = 1 \rightarrow$ modelo perfecto. $R^2 = 0 \rightarrow$ el modelo no mejora sobre predecir la media.

R^2 visualmente — observado vs predicho



Cuanto más "pegados" los puntos a la diagonal $\hat{y} = y$, más alto el R^2 .

¿Qué Variables Importán? El p-valor

- Cada coeficiente del OLS trae una columna Probability en el output.
- Eso es el **p-valor** del coeficiente.
- **Responde una pregunta concreta:** si $\beta = 0$, ¿cuál es la probabilidad de que por puro azar mi muestra me dé un coeficiente tan grande como el que estoy viendo?"
- **Regla práctica:**
 - ▶ **p < 0.05** $\Rightarrow$ la variable importa (rechazo $H_0: \beta = 0$).
 - ▶ **p > 0.05** $\Rightarrow$ no la considero significativa (podría ser azar).

OLS sobre Airbnb ¿Qué muestran R^2 y los p-value?

OLS — $R^2 = 0.6685$ · N = 6110 · k = 12


Variable	Coef	p-valor
CONSTANT	+4.3796	0.000 ***
accommodates	+0.0836	0.000 ***
bathrooms	+0.1908	0.000 ***
bedrooms	+0.1507	0.000 ***
beds	-0.0415	0.000 ***
d2balboa	+0.0016	0.089
rt_Private_room	-0.5530	0.000 ***
rt_Shared_room	-1.2355	0.000 ***
pg_Condominium	+0.1405	0.000 ***
pg_House	-0.0133	0.363
pg_Other	+0.1412	0.000 ***
pg_Townhouse	-0.0458	0.183

Lectura del Resultado

- ▶ **$R^2 = 0.6685$** : el modelo explica el 67% de la varianza de $\log(\text{precio})$.
- ▶ **$p < 0.05$ en bedrooms, bathrooms, accommodates**: atributos físicos significativos en la dirección esperada.
- ▶ **Coeficientes negativos $rt_Private_room$, rt_Shared_room** : habitación privada o compartida abarata vs casa o departamento completo.
- ▶ **Quedan ~33% de la varianza sin explicar**
¿Dónde está? ¿Se distribuye al azar en el espacio?


Diagnóstico: el Mapa de Residuos

$$y_i - \hat{y}_i$$



Si OLS captura toda la señal, los residuos deberían verse repartidos AL AZAR en el mapa.

Costa vs Interior. Un test t sobre los Residuos



El OLS subestima sistemáticamente los precios costeros y sobreestima los del interior.

Moran's I Sobre los Residuos

- **Moran's I (residuos OLS) = +0.1411**
- **p-valor (999 permutaciones) = 0.001**
- Positivo y altamente significativo → los residuos vecinos se parecen entre sí más de lo que cabría esperar por azar.
- **El supuesto de independencia NO se cumple. Hay que meter el espacio en el modelo.**

SLX. Primera Forma de Incluir el Espacio

$$\log(P_i) = \alpha + \sum_k X_{ik} \beta_k + \sum_k (WX)_{ik} \gamma_k + \varepsilon_i$$

- **Idea:** agregar como predictores el PROMEDIO de cada variable entre los vecinos.
- Los γ_k son **efectos de spillover (efectos indirectos)**: cuánto influye en el precio de i lo que pasa con sus vecinos.
- **Ejemplo:** estar rodeado de propiedades grandes (alto accommodates promedio) encarece la mía, aún manteniendo fijos sus atributos.

OLS vs SLX . ¿Qué Pasó con la Autocorrelación?

OLS vs SLX — el SLX mejora pero deja autocorrelación

Modelo	R ²	# variables	Moran I residuos	p-valor Moran
OLS	0.6685	11	+0.1411	0.001
SLX	0.6871	14	+0.1048	0.001

El SLX mejora el R² y baja Moran's I, pero **todavía queda autocorrelación significativa.**

La dependencia no viene solo de los atributos de los vecinos. Hay algo más.

Próxima Clase

Dos formas más profundas de incorporar el espacio:

- **Spatial Error Model (SEM)**

La dependencia está en el ERROR. Variables omitidas espacialmente correlacionadas. Se estima λ .

- **Spatial Lag Model (SAR)**

El precio de una propiedad depende del PRECIO de sus vecinas. Proceso endógeno $\rightarrow$ se estima ρ con variables instrumentales / GMM.

- **Más heterogeneidad**

Efectos fijos por barrio, regímenes costa/interior, interpretación de efectos directos vs indirectos.

Ideas Para LLevarse

- **OLS es un buen punto de partida**
pero asume independencia entre errores y eso falla en el espacio.
- **Dos métricas para leer un OLS**
 R^2 (cuánto explica) y test t (cuáles coeficientes son significativos).
- **Mapa de residuos + Moran's I**
son las dos herramientas básicas para detectar dependencia espacial.
- **El SLX es el primer paso**
modelar los spillovers exógenos. SEM y SAR vienen en la siguiente.