

Análisis de Datos Espaciales

Clase 10: Spatial Feature Engineering

Daniela Opitz

Departamento de Informática
Universidad Técnica Federico Santa María

2026

La pregunta de hoy

- En clases anteriores partimos siempre de datos ya listos para el análisis.
- Pero en la práctica los datos casi nunca vienen con todas **las variables que necesitamos**.
- La solución: construirlas usando la geografía como herramienta.
- Y al final de la clase respondemos: **¿las features espaciales mejoran la regresión?**


Outline

- 1.** Map matching: conectar datasets distintos por geografía.
 - Buffer + sjoin: contar POIs a 500 m.
 - Raster sampling: elevación desde el DEM.
 - Punto en polígono: ingreso del census tract.
- 2.** ¿Mejoran la regresión? OLS, SAR y SEM con y sin features.
- 3.** Lección: features y modelos espaciales son complementarios.

Caso: Airbnb en San Diego

San Diego: Airbnbs y puntos de interés (OSM)

● Airbnbs
● POIs



- 6110 propiedades Airbnb
- 1 920 POIs (restaurantes, bares, cafés)
- 628 census tracts



Operación 1: Buffer + sjoin

Buffer de 500 m — cada círculo captura los POIs dentro de su radio





1. Crear un buffer de 500 m alrededor de cada propiedad.
2. **sjoin**: ¿qué POIs caen dentro del buffer?
3. Agrupar y contar por Airbnb.

Resultado: POIs a 500 m por Propiedad



La costa y el centro concentran la mayor densidad gastronómica y los precios más altos.



Operación 2: Raster sampling (DEM)




DEM NASADEM (izquierda) para cada Airbnb extraemos el valor del píxel más cercano con **`rasterstats.point_query()`** elevación en metros (derecha).

Operación 3: Punto en polígono

Ingreso mediano por census tract



Ingreso heredado por cada Airbnb



- Cada Airbnb hereda los atributos del **tract** que lo contiene: median_hh_income, pct_bachelor, total_pop
- **Supuesto:** distribución homogénea dentro del tract

Resumen: features de map matching

Features de map matching construidas en esta clase

Feature	Tipo	Operación	¿Qué mide?
n_pois_500m	Map matching	Buffer + sjoin	¿Cuántos restaurantes/bares hay cerca?
elevacion_m	Map matching	Raster sampling	Altura sobre el nivel del mar (DEM)
median_hh_income	Map matching	Punto en polígono	Ingreso mediano del census tract
pct_bachelor	Map matching	Punto en polígono	% con educación universitaria

Todas usan dos operaciones básicas: buffer / sjoin / point_query. La geografía actúa como llave de cruce entre datasets.

¿Las Features Mejoran la Regresión?

Tenemos el OLS, SAR y SEM de la clase 08/09 sobre los mismos datos.

Ahora repetimos los tres modelos agregando las 4 features de map matching:

- n_pois_500m
- elevacion_m
- median_hh_income
- pct_bachelor

Comparamos R^2 / pseudo- R^2 y AIC para los 6 modelos.

Comparación: 6 modelos


☒ = mejor modelo (AIC más bajo)

Modelo	R^2 / pR^2	AIC	Qué agrega
OLS base (clase 08)	0.669	7999	solo atributos físicos
SAR base	0.704	7365	dependencia espacial ($p = 0.304$)
SEM base	0.666	7480	error espacial ($\lambda = 0.467$)
OLS + map matching	0.698	7438	base + entorno territorial
SAR + map matching ★	0.714	7137	dependencia + entorno ($p = 0.234$)
SEM + map matching	0.698	7265	error + entorno ($\lambda = 0.309$)

- pR^2 (seudo R^2): $cov(y, \hat{y})$
- AIC: que tan bien ajusta el modleo penalizado por el número de parámetros
- AIC más bajo = mejor modelo. ★ SAR + map matching gana.

R² comparativo

¿Mejora la regresión con features espaciales?



El SAR base ya era competitivo. Las features suman más al OLS y al SEM que al SAR.

Resumen

1. Features espaciales y modelos espaciales son complementarios.

No son sustitutos. Las features atacan la autocorrelación desde las variables explicativas; SAR/SEM la modelan en la estructura.

2. Las features ayudan más donde el modelo ya no tenía con qué.

El SAR base capturaba mucho vía el lag de Y. El OLS y el SEM se benefician más.

3. El mejor resultado combina los dos enfoques.

SAR + map matching → AIC más bajo y R^2 más alto.