

Análisis de Datos Espaciales

Clase 11: Regresión Geográficamente Ponderada

Daniela Opitz

Departamento de Informática
Universidad Técnica Federico Santa María

2026

La Pregunta de Hoy

- Todos los modelos de regresión espacial (OLS, SLX, SEM, SAR) entregan **un solo coeficiente para todo San Diego.**
- Pero, ¿el efecto de un dormitorio (o de la cercanía a Balboa Park) es el mismo toda el área?
- GWR permite que el efecto **cambie según la ubicación.**

Airbnb

	log_price	accommodates	bedrooms	bathrooms	d2balboa	geometry
0	6.052089	5	2.0	2.0	2.972077	POINT (487849.961 3624022.580)
1	5.323010	6	2.0	1.0	11.501385	POINT (476352.113 3627393.256)
2	4.595120	2	1.0	1.0	2.493893	POINT (486772.302 3623943.385)
3	4.276666	2	1.0	1.0	22.293757	POINT (485725.689 3643659.514)
4	4.007333	2	1.0	1.0	6.829451	POINT (479510.620 3622708.972)

Recordatorio: la regresión lineal (OLS)

$$\log(\text{precio}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

Qué es cada término

- y lo que queremos explicar (el log-precio)
- β_0 intercepto: el valor base (cuando todas las $x = 0$)
- β_k el efecto de la variable x_k
- ε el error: lo que el modelo no explica

Cómo se interpreta β_k

β_k = cuánto cambia y si x_k sube 1 unidad, manteniendo las demás constantes.

Ejemplo: $\beta_{\text{capacidad}} = +0.42$

cada huésped extra sube el log-precio en 0.42 (en promedio, en toda la ciudad).

En OLS, cada coeficiente es UN solo número para todos los datos. GWR lo dejará variar en el espacio.

Outline

1. La idea: una regresión local por cada punto (kernel + bandwidth).
2. Coeficientes locales: un mapa por variable.
3. Diagnóstico: R^2 local y significancia con corrección.
4. Comparación de los 5 modelos: ¿cuál es mejor?
5. Cierre del curso.

Regresiones


Cinco formas de incorporar el espacio

Modelo	Ecuación	Qué incorpora del espacio
OLS	$y = X\beta + \varepsilon$	nada (β global)
SLX	$y = X\beta + WX\gamma + \varepsilon$	contexto vecino
SEM	$u = \lambda Wu + \varepsilon$	error espacial
SAR	$y = \rho Wy + X\beta + \varepsilon$	contagio en y
GWR	$y = X \cdot \beta(u,v) + \varepsilon$	β varía en el espacio


Las cuatro primeras mantienen β global. GWR es la única que permite que varíe.

Regresión local en cada punto

- Una regresión por punto.
- Los vecinos se pesan por cercanía.
- Fuera del rango pesan 0



Kernel y bandwidth



El bandwidth (radio) determina el grado de localidad de cada regresión. Se selecciona minimizando el AICc; aquí es adaptativo (nº de vecinos).

Kernel y bandwidth

Kernel bisquare


$$w_{ij} = \left[1 - \left(\frac{d_{ij}}{b} \right)^2 \right]^2 \quad \text{si } d_{ij} < b$$

$$w_{ij} = 0 \quad \text{si } d_{ij} \geq b$$



d_{ij} = distancia entre i y j b = bandwidth (radio)

Coeficiente local: capacidad de

Cap. huéspedes (global = +0.421)




Cap. huéspedes (global = +0.421) · zoom núcleo urbano




Coeficiente local: dormitorios

Dormitorios (global = +0.099)




Dormitorios (global = +0.099) · zoom núcleo urbano




Coeficiente local: baños

Baños (global = +0.121)




Baños (global = +0.121) · zoom núcleo urbano




Coeficiente local: distancia a B. Park

Distancia a Balboa (global = -0.003)



Distancia a Balboa (global = -0.003) · zoom núcleo urbano




¿Qué es t ?

$$t = \frac{\hat{\beta}}{SE(\hat{\beta})} = \frac{\text{coeficiente}}{\text{su error}}$$

Mide cuántas veces más grande es el efecto que su propia incertidumbre.

= cuántos errores estándar (*SE*) separan el coeficiente del 0.


- $|t|$ grande:
señal fuerte, el efecto destaca sobre el ruido (significativo).
- $|t| \approx 0$:
el efecto no se distingue del ruido.



t es la señal (el coeficiente) medida en unidades de su ruido (el error).


Umbral de significancia t en GWR

UNA prueba (en un punto)



= decidir "¿significativo aquí?"

LAS 6.110 pruebas = el mapa



cada punto es una prueba: rojo = sí, gris = no

Cada prueba es un punto respondiendo "¿influye aquí, sí o no?". Las 6.110 respuestas son el mapa.

Umbral de significancia t en GWR

Quiero 95% de confianza: $\alpha = 0.05$

el riesgo de error que aceptas

$$\alpha^* = \frac{\alpha \cdot k}{\text{ENP}}$$

mucho más chico que 0.05

ppf: área $\rightarrow t$

$$\text{umbral } t = \text{ppf}(1 - \alpha^*/2) \approx 3.5$$

de área a posición en el eje

comparas cada punto

Significativo donde $|t_{\text{local}}| > 3.5$

se aplica a los 6.110 puntos

ENP: depende del problema

Número efectivo de parámetros:
cuántas regresiones son realmente
distintas, no las 6.110.

bandwidth chico: ENP alto,
umbral más exigente.

bandwidth grande: ENP bajo,
umbral cercano a 2.

El umbral no es un número mágico: sale de tu confianza (95%) y de la flexibilidad del modelo (ENP).

El caso de la distancia a Balboa

¿Dónde es significativa la distancia a Balboa?
(con corrección por comparaciones múltiples)




Según el OLS, el coeficiente es cercano a cero (- 0,003, sin efecto aparente).

- GWR revela que sí es relevante, con efectos de signo opuesto según la zona que se compensan al promediarse.
- *El coeficiente global cercano a cero no indica ausencia de efecto: refleja efectos opuestos que se cancelan entre zonas.*
- Con corrección por comparaciones múltiples, es significativa solo en ~2% del mapa.

¿Dónde ajusta mejor el modelo? R^2 local


El modelo explica entre 0.08 y 0.90 según la zona. Donde es bajo hay variables omitidas (vista, ruido, atractivos).

R^2 local: dónde el modelo explica bien el precio (y dónde no)



Coeficientes locales vs global

Coeficientes locales (cajas) vs OLS global (diamante naranja)



El coeficiente global (diamante naranja) es solo el promedio de una distribución ancha que a veces cruza el cero. GWR no contradice al OLS: lo descompone.

Interpretación del caso de San Diego

- 1. La capacidad es el factor dominante, pero no por igual.** Efecto positivo en toda la ciudad, mayor en el interior (+0.40) que en la costa (+0.25): donde no hay prima por ubicación, el tamaño tiene más incidencia.
- 2. La distancia a Balboa: el efecto que el promedio ocultaba.** El coeficiente global es cercano a cero, pero localmente es relevante: en la costa el efecto es marcadamente positivo (+1.35) y en el interior, casi nulo (-0.07). El promedio sobre la ciudad lo enmascaraba.
- 3. Dónde el modelo ajusta peor.** El R^2 local va de 0.08 a 0.90; en ~11% de las propiedades el ajuste es bajo ($R^2 < 0.4$): indicio de variables no observadas (vista al mar, ruido, atractivos turísticos).
- 4. Cautela estadística.** La distancia a Balboa es significativa solo en ~2% del mapa (con corrección): en el resto no se distingue de cero.

Comparación: los 5 modelos

Fila resaltada = mejor AIC. Moran residual cerca de 0 = sin autocorrelación pendiente

Modelo	R^2 / pR^2	AIC	Moran resid.	Término clave
OLS	0.552	9832	+0.194	—
SLX	0.588	9327	+0.132	γ (lags de X)
SEM	0.549	8868	-0.011	$\lambda = +0.68$
SAR	0.621	8875	+0.021	$\rho = +0.48$
GWR ★	0.717	8089	-0.013	bw = 125 vec.

Mismos datos y variables. GWR es superior en ajuste (AIC); SEM, SAR y GWR dejan los residuos sin autocorrelación.

¿Cuál es mejor? Depende de la pregunta

“Mejor” no es una propiedad del modelo, sino de la pregunta de investigación

Si el objetivo es...	El más adecuado es...	Por qué
Mejor ajuste / menor AIC	GWR	adapta β a cada zona
Eliminar autocorrelación residual	SEM / SAR	diseñados para ello
Efecto global defendible	SEM / SAR	inferencia válida
Determinar dónde pesa cada variable	GWR	su salida es un mapa
Modelo base de referencia	OLS	punto de partida

Resumen

1. El resultado de GWR es un mapa, no una cifra. Pasamos de “¿cuánto vale?” a “¿cuánto vale aquí?”.
2. El promedio puede inducir a error cuando el efecto varía en el espacio. Un coeficiente global cercano a cero puede ocultar efectos opuestos entre zonas.
3. GWR y los modelos globales no son excluyentes. GWR destaca en ajuste y exploración espacial; SEM y SAR, en inferencia global.