

# Análisis de Datos Espaciales

## **Clase 11: Regresión Geográficamente Ponderada**

**Daniela Opitz**

Departamento de Informática  
Universidad Técnica Federico Santa María

2026

# La Pregunta de Hoy

- Todos los modelos de regresión espacial (OLS, SLX, SEM, SAR) entregan **un solo coeficiente para todo San Diego.**
- Pero, ¿el efecto de un dormitorio (o de la cercanía a Balboa Park) es el mismo toda el área?
- GWR permite que el efecto **cambie según la ubicación.**

# Airbnb

|   | log_price | accommodates | bedrooms | bathrooms | d2balboa  | geometry                          |
|---|-----------|--------------|----------|-----------|-----------|-----------------------------------|
| 0 | 6.052089  | 5            | 2.0      | 2.0       | 2.972077  | POINT (487849.961<br>3624022.580) |
| 1 | 5.323010  | 6            | 2.0      | 1.0       | 11.501385 | POINT (476352.113<br>3627393.256) |
| 2 | 4.595120  | 2            | 1.0      | 1.0       | 2.493893  | POINT (486772.302<br>3623943.385) |
| 3 | 4.276666  | 2            | 1.0      | 1.0       | 22.293757 | POINT (485725.689<br>3643659.514) |
| 4 | 4.007333  | 2            | 1.0      | 1.0       | 6.829451  | POINT (479510.620<br>3622708.972) |

## Recordatorio: la regresión lineal (OLS)

$$\log(\text{precio}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

### Qué es cada término

- $y$  lo que queremos explicar (el log-precio)
- $\beta_0$  intercepto: el valor base (cuando todas las  $x = 0$ )
- $\beta_k$  el efecto de la variable  $x_k$
- $\varepsilon$  el error: lo que el modelo no explica

### Cómo se interpreta $\beta_k$

$\beta_k$  = cuánto cambia  $y$  si  $x_k$  sube 1 unidad, manteniendo las demás constantes.

Ejemplo:  $\beta_{\text{capacidad}} = +0.42$

cada huésped extra sube el log-precio en 0.42 (en promedio, en toda la ciudad).

En OLS, cada coeficiente es UN solo número para todos los datos. GWR lo dejará variar en el espacio.

# Outline

1. La idea: una regresión local por cada punto (kernel + bandwidth).
2. Coeficientes locales: un mapa por variable.
3. Diagnóstico:  $R^2$  local y significancia con corrección.
4. Comparación de los 5 modelos: ¿cuál es mejor?
5. Cierre del curso.

# Regresiones


Cinco formas de incorporar el espacio

| Modelo     | Ecuación                               | Qué incorpora del espacio   |
|------------|----------------------------------------|-----------------------------|
| <b>OLS</b> | $y = X\beta + \varepsilon$             | nada ( $\beta$ global)      |
| <b>SLX</b> | $y = X\beta + WX\gamma + \varepsilon$  | contexto vecino             |
| <b>SEM</b> | $u = \lambda Wu + \varepsilon$         | error espacial              |
| <b>SAR</b> | $y = \rho Wy + X\beta + \varepsilon$   | contagio en y               |
| <b>GWR</b> | $y = X \cdot \beta(u,v) + \varepsilon$ | $\beta$ varía en el espacio |


*Las cuatro primeras mantienen  $\beta$  global. GWR es la única que permite que varíe.*

# Regresión local en cada punto

- Una regresión por punto.
- Los vecinos se pesan por cercanía.
- Fuera del rango pesan 0



# Kernel y bandwidth



El bandwidth (radio) determina el grado de localidad de cada regresión. Se selecciona minimizando el AICc; aquí es adaptativo ( $n^\circ$  de vecinos).

# Kernel y bandwidth

Kernel bisquare


$$w_{ij} = \left[ 1 - \left( \frac{d_{ij}}{b} \right)^2 \right]^2 \quad \text{si } d_{ij} < b$$

$$w_{ij} = 0 \quad \text{si } d_{ij} \geq b$$


$d_{ij}$  = distancia entre  $i$  y  $j$      $b$  = bandwidth (radio)

# Coeficiente local: capacidad de

Cap. huéspedes (global = +0.421)




Cap. huéspedes (global = +0.421) · zoom núcleo urbano




# Coeficiente local: dormitorios

Dormitorios (global = +0.099)




Dormitorios (global = +0.099) · zoom núcleo urbano




# Coeficiente local: baños

Baños (global = +0.121)




Baños (global = +0.121) · zoom núcleo urbano




# Coeficiente local: Distancia a Balboa Park

Distancia a Balboa (global = -0.003)



Distancia a Balboa (global = -0.003) · zoom núcleo urbano



# El caso de la distancia a Balboa

¿Dónde es significativa la distancia a Balboa?  
(con corrección por comparaciones múltiples)




**Según el OLS, el coeficiente es cercano a cero (- 0,003, sin efecto aparente).**

- GWR revela que sí es relevante, con efectos de signo opuesto según la zona que se compensan al promediarse.
- *El coeficiente global cercano a cero no indica ausencia de efecto: refleja efectos opuestos que se cancelan entre zonas.*
- Con corrección por comparaciones múltiples, es significativa solo en ~2% del mapa.

# ¿Dónde ajusta mejor el modelo? $R^2$ local


El modelo explica entre 0.08 y 0.90 según la zona. Donde es bajo hay variables omitidas (vista, ruido, atractivos).

$R^2$  local: dónde el modelo explica bien el precio (y dónde no)



# Coeficientes locales vs global

Coeficientes locales (cajas) vs OLS global (diamante naranja)



*El coeficiente global (diamante naranja) es solo el promedio de una distribución ancha que a veces cruza el cero. GWR no contradice al OLS: lo descompone.*

# Interpretación del caso de San Diego

- 1. La capacidad es el factor dominante, pero no por igual.** Efecto positivo en toda la ciudad, mayor en el interior (+0.40) que en la costa (+0.25): donde no hay prima por ubicación, el tamaño tiene más incidencia.
- 2. La distancia a Balboa: el efecto que el promedio ocultaba.** El coeficiente global es cercano a cero, pero localmente es relevante: en la costa el efecto es marcadamente positivo (+1.35) y en el interior, casi nulo (-0.07). El promedio sobre la ciudad lo enmascaraba.
- 3. Dónde el modelo ajusta peor.** El  $R^2$  local va de 0.08 a 0.90; en ~11% de las propiedades el ajuste es bajo ( $R^2 < 0.4$ ): indicio de variables no observadas (vista al mar, ruido, atractivos turísticos).
- 4. Cautela estadística.** La distancia a Balboa es significativa solo en ~2% del mapa (con corrección): en el resto no se distingue de cero.

# Comparación: los 5 modelos

Fila resaltada = mejor AIC. Moran residual cerca de 0 = sin autocorrelación pendiente

| Modelo       | $R^2$ / $pR^2$ | AIC  | Moran resid. | Término clave        |
|--------------|----------------|------|--------------|----------------------|
| <b>OLS</b>   | 0.552          | 9832 | +0.194       | —                    |
| <b>SLX</b>   | 0.588          | 9327 | +0.132       | $\gamma$ (lags de X) |
| <b>SEM</b>   | 0.549          | 8868 | -0.011       | $\lambda = +0.68$    |
| <b>SAR</b>   | 0.621          | 8875 | +0.021       | $\rho = +0.48$       |
| <b>GWR ★</b> | 0.717          | 8089 | -0.013       | bw = 125 vec.        |

*Mismos datos y variables. GWR es superior en ajuste (AIC); SEM, SAR y GWR dejan los residuos sin autocorrelación.*

# ¿Cuál es mejor? Depende de la pregunta

“Mejor” no es una propiedad del modelo, sino de la pregunta de investigación

| Si el objetivo es...                       | El más adecuado es... | Por qué                    |
|--------------------------------------------|-----------------------|----------------------------|
| <b>Mejor ajuste / menor AIC</b>            | GWR                   | adapta $\beta$ a cada zona |
| <b>Eliminar autocorrelación residual</b>   | SEM / SAR             | diseñados para ello        |
| <b>Efecto global defendible</b>            | SEM / SAR             | inferencia válida          |
| <b>Determinar dónde pesa cada variable</b> | GWR                   | su salida es un mapa       |
| <b>Modelo base de referencia</b>           | OLS                   | punto de partida           |

# Resumen

1. El resultado de GWR es un mapa, no una cifra. Pasamos de “¿cuánto vale?” a “¿cuánto vale aquí?”.
2. El promedio puede inducir a error cuando el efecto varía en el espacio. Un coeficiente global cercano a cero puede ocultar efectos opuestos entre zonas.
3. GWR y los modelos globales no son excluyentes. GWR destaca en ajuste y exploración espacial; SEM y SAR, en inferencia global.